

Relatório de Limpeza e Preparação de Dados: Previsão de Churn

Projeto: Módulo 08 - Análise e Limpeza de Dados de Telecomunicações

1. Introdução e Contexto do Desafio

O objetivo deste projeto foi tratar uma base de dados reais de uma empresa de telecomunicações, cujo objetivo futuro é prever a taxa de abandono dos clientes (Variável *Churn*). Foi efetuado um trabalho de limpeza, onde foram corrigidos tipos de dados inadequados, tratados valores ausentes (com justificativas analíticas de exclusão ou imputação) e padronizados valores categóricos inconsistentes.

2. Execução: Passo a Passo

Passo 1: Carregamento da Base e Verificação Inicial

O ficheiro .csv foi carregado na plataforma com sucesso. Durante a leitura, foi identificada a necessidade de declarar o parâmetro `sep=';`, dado que os dados não estavam separados por vírgula padrão. A base inicial contava com 2.500 linhas e 16 colunas.

Passo 2: Correção de Tipos de Dados Inadequados

Após a inspeção visual dos metadados através da função `.info()`, foi detetada uma inconsistência de tipagem:

Ação: A coluna `Idoso` estava classificada como tipo numérico (`int64`).

Correção: Sendo uma característica que representa uma classificação binária (sim/não), a coluna foi transformada para o tipo texto (`object`) utilizando a função `.astype(str)`. Esta alteração previne que modelos futuros ou visualizações tentem realizar operações matemáticas ilógicas (como médias) nesta variável categórica.

Passos 3 e 4: Diagnóstico e Tratamento Crítico de Dados Faltantes

Foi realizado o levantamento dos dados nulos, revelando 4 colunas com problemas. As decisões de tratamento foram tomadas com base em critérios estatísticos e de negócio:

PhoneService (59.28% de dados ausentes):

Decisão: Exclusão total da coluna (`drop`).

Justificativa: A perda massiva de quase 60% dos dados inviabiliza qualquer técnica de imputação. Preencher esta quantidade de dados significaria fabricar a maioria da realidade da variável, gerando um forte viés artificial.

Churn (0.20% - 5 linhas ausentes):

Decisão: Exclusão apenas das linhas afetadas (dropna).

Justificativa: O *Churn* é a **variável alvo** (o que se deseja prever). A regra de ouro em *Machine Learning* é nunca imputar dados na variável alvo para não treinar o algoritmo com falsidades. Sendo a perda irrelevante (5 clientes), a exclusão cirúrgica foi a melhor abordagem.

Pagamento_Mensal (13.00% de dados ausentes - Variável Numérica):

Decisão: Substituição dos valores ausentes pela **Mediana** (fillna).

Justificativa: Em variáveis financeiras, a Média é frequentemente distorcida por *outliers* (valores extremos muito altos ou muito baixos). A Mediana foi escolhida por ser uma medida de tendência central mais robusta, representando o pagamento do "cliente típico" sem sofrer distorções.

Genero (0.48% de dados ausentes - Variável Categórica):

Decisão: Substituição dos valores ausentes pela **Moda** (fillna).

Justificativa: Tratando-se de uma variável de texto, não é possível calcular médias ou medianas. A imputação pelo valor mais frequente (Moda) é a técnica recomendada para garantir a preservação da amostra sem corromper significativamente a distribuição original.

Passo 5: Padronização de Valores Categóricos Inconsistentes

Coluna Genero: Valores como 'F', 'f' e 'M' foram padronizados exclusivamente para 'Female' e 'Male'.

Coluna Servico_Internet: O valor 'dsl' (em minúsculas) foi padronizado para 'DSL' (em maiúsculas), igualando os restantes registos do serviço.

Passo Extra: Padronização dos Nomes das Colunas

Para garantir a qualidade e o profissionalismo do *DataFrame*, os nomes das 15 colunas finais foram traduzidos para Português e formatados de acordo com as boas práticas de programação em *Snake Case* (letras minúsculas unidas por _).

3. Conclusão

A base de dados foi tratada com sucesso. O *DataFrame* final (df) encontra-se com 2.495 linhas, 15 colunas padronizadas, 0% de dados ausentes e com todos os dados tipificados corretamente.